

基于改进混沌蚁群算法的无人机航路规划*

刘 蓉¹ 杨 帆² 张 衡³

(1 南京航空航天大学无人机研究院 南京 210016)

(2 江苏航空职业技术学院航空工程学院 江苏镇江 212134)

(3 南京航空航天大学自动化学院 南京 210016)

摘 要: 针对蚁群算法在无人机航路规划中易出现局部极值、收敛效率低的缺陷,设计了一种基于改进混沌蚁群算法的无人机航路规划方法。该方法利用混沌优化机制初始化蚁群的信息素,采用变尺度混沌局部再搜索机制和信息素挥发因子的自适应更新策略,增强了算法的全局寻优能力和搜索效率,并在启发函数中添加目标指标,增强其搜索方向性。仿真结果表明,该方法与基于蚁群算法的航路规划方法相比,在规划航路时能跳出局部最优解,且收敛速度显著提高,更好地实现了航路优化。

关键词: 混沌蚁群算法;航路规划;局部最优;初始信息素;启发函数

中图分类号: V249 **文献标识码:** A **文章编号:** 1674-909X(2018)06-0041-08

Path Planning for UAV Based on Improved Chaotic Ant Colony Algorithm (CACA)

LIU Rong¹ YANG Fan² ZHANG Heng³

(1 UAV Research Institute of Nanjing University of Aeronautics and Astronautics, Nanjing 210016, China)

(2 Department of Aeronautical Engineering, Jiangsu Aviation Technical College, Zhenjiang 212134, Jiangsu, China)

(3 College of Automation Engineering, Nanjing University of Aeronautics and Astronautics, Nanjing 210016, China)

Abstract: Aimed at the deficiency of the ant colony algorithm (ACA) on easily falling into local optimum and the low convergence efficient in the process of unmanned aerial vehicle (UAV) path planning, a path planning method for UAV based on improved chaotic ant colony algorithm (CACA) is designed. With the chaotic optimization mechanism, the initial pheromone value is set. The local re-search mechanism based on variable metric chaos and the adapted update strategy of pheromone volatilization factor are adopted. Thus, the global optimization ability and search efficiency of the method are enhanced. Besides, the target index is appended to the heuristic function of ACA to strengthen the search direction. Simulation results show that, compared with the path planning method based on ACA, the method based on CACA can avoid the local optimum solution, and its convergence speed is obviously increased. Thus, the path optimization is better realized.

Key words: chaotic ant colony algorithm (CACA); path planning; local optimum; initial pheromone; heuristic function

* 基金项目:中央高校基本科研业务费专项资金(NS2018059 和 NS 2017209)和陆军装备部“十三五”预研(30102080101)课题资助项目。

收稿日期:2018-04-06

引用格式:刘蓉,杨帆,张衡. 基于改进混沌蚁群算法的无人机航路规划[J]. 指挥信息系统与技术,2018,9(6):41-48.

LIU Rong, YANG Fan, ZHANG Heng. Path planning for UAV based on improved chaotic ant colony algorithm (CACA)[J]. Command Information System and Technology, 2018,9(6):41-48.

0 引言

航路规划指参考各种地理、气象和敌方等外部环境信息,结合自身性能、飞行要求、油耗、避障和任务约束等因素,为无人机规划出 1 条或多条安全系数大、突防概率高、飞行时间短的最优或可行航路,以保证其圆满完成任务并安全返回^[1-2]。无人机航路规划指在环境和威胁等特定约束条件下,寻找从起点到终点且满足无人机性能指标的最优、可行的航路。

目前国内外关于航路规划算法领域也开展了大量研究,并提出了行之有效的方法。动态规划法起初应用于解决旅行商最优问题(TSP),之后广泛应用于寻找最优路径^[3-5],该方法主体思想是将 1 个多步最优问题转换为多个 1 步最优问题,从而降低了航路规划建模的难度,提高了航路规划的可实现性,但随着无人机航路规划空间愈发复杂,动态规划法会出现组合爆炸问题,导致其时间复杂度极大提升,难以适用于实际的航迹规划。Voronoi 图算法将三维空间中的航路规划问题转换为二维平面图形的规划问题,因此直观性强,先根据已知威胁障碍物信息,遵循威胁点距离 Voronoi 图边距离最大准则^[6],构造 Voronoi 图,在此基础上进行航迹寻优,但是该方法不适用于存在动态威胁的战场环境。遗传算法(GA)通过模拟生物进化机制,遵循自然界优胜劣汰的进化准则,不断将待求解逼近最优解^[7],然而该算法在进行航路规划时会产生收敛速度慢、易出现局部极值甚至搜索失败的问题,尤其对于存在动态威胁的复杂飞行环境,该算法难以获取可行航路,只能与其他优化算法组合规划出有效航路。 A^* 算法作为一种典型的确定型搜索算法,其搜索方式代表了确定型搜索算法寻优的过程,利用启发信息构造启发函数^[8-10],有效提高了算法的收敛性和算法效率,然而实际飞行环境中存在着各种不确定因素,无法构造出精确的启发函数,且 A^* 算法的效率直接取决于构造的启发函数的品质,因而容易出现搜索失败。蚁群算法(ACA)是一种仿生群体智能算法,该算法通过模拟蚁群从巢穴到食物源的觅食过程来寻找满足航路代价指标的可行路径^[11-12],蚁群算法由于其多样性、较强的鲁棒性、优秀的分布式计算能力、正反馈以及易于与其他算法结合等诸多优点,广泛应用于路径寻优领域,然而蚁群算法基于随机搜索机制进行状态转移,使得算法收敛效率较低,同时该算法的正反馈特性可能造成局部路径上的信息素含量堆积过量,使算法陷入局部最优甚至停滞状态。

本文针对蚁群算法在规划航路时易出现局部极值、收敛效率低的问题,提出了蚁群算法的改进措施;研究并改进了混沌优化算法,将改进算法与改进的蚁群算法相结合得到一种改进的混沌蚁群算法(CACA),实现了无人机的航路规划。

1 无人机航路规划数学建模

无人机在飞行过程中需规避地面、空中的威胁或障碍物,以满足安全飞行的要求,同时又需考虑一定的代价函数。本文的威胁主要考虑雷达,代价函数主要考虑燃料代价。在此基础上建立无人机航路规划的代价函数。

1.1 雷达威胁建模

无人机在执行任务时,不可避免地会面临敌方雷达的威胁。敌方雷达通过探测、识别和追踪无人机,并向敌方防空阵地发送信号,最终引导防空武器击毁无人机。因此,尽可能降低无人机受到的雷达威胁是保证无人机安全飞行的重要条件。

雷达特征方程^[13-14]如下:

$$P_r = \frac{P_t G_r^2 \lambda_r^2 \sigma_r^2 F_r^4}{(4\pi)^3 R_r^4 C_B L_r} \quad (1)$$

其中, P_r 为雷达接收到反射波的功率; P_t 为雷达发射功率; G_r 为雷达天线增益; λ_r 为信号波长; σ_r 为雷达的目标反射截面积; F_r 为发射/接收方向图传播系数; R_r 为雷达与目标间的距离; C_B 为滤波器匹配到信号波形的系数; L_r 为损耗因子。

在雷达不受干扰前提下,雷达探测到目标的概率取决于雷达接收端获取信号的品质,即 P_r 值。设雷达能探测到目标信号的最小值为 P_{rmin} 。当 $P_r \geq P_{rmin}$ 时,雷达可以探测并锁定目标;反之,当 $P_r < P_{rmin}$ 时,目标可以躲避雷达探测。由式(1)可知,令雷达特性和传播介质等参数为常数 C ,则 P_r 与 R_r^4 成反比例关系,两者关系如下:

$$P_r \propto C/R_r^4 \quad (2)$$

可见,当 $P_r = P_{rmin}$ 时,雷达的最大扫描范围 R_{rmax} 也随之确定。因此,当 $P_r < P_{rmin}$,目标可以躲避雷达探测,等价于当航路上每个航点与雷达的距离 $R_r > R_{rmax}$ 成立时,无人机可有效规避雷达威胁。假设航路由 m 个航点组成, j 为这些航点中任意一点,所以无人机在航点 j 受到雷达的威胁程度 $T_{r,j}$ 与无人机在 j 处与雷达间距离 $R_{r,j}$ 满足如下关系:

$$T_{r,j} = C/R_{r,j}^4 \quad (3)$$

无人机在整个航路上受到第 i 个雷达的威胁程度如下:

$$T_{hr,i} = \sum_{j=1}^m T_{r,j} \quad (4)$$

依此类推,假设存在 m_r 个雷达,则无人机受到的雷达威胁 T_{total} 为:

$$T_{total} = f_r(T_{hr,0}, T_{hr,1}, \dots, T_{hr,m_r}) \quad (5)$$

其中, f_r 为根据每个雷达对无人机影响力设置的函数。

1.2 燃料代价建模

假设无人机的速度和高度基本不变^[15-16],不考虑地形威胁,无人机的燃油消耗与无人机的飞行路径长度 L 满足:

$$\omega_f = k_f L \quad (6)$$

1.3 航路代价函数

航路代价函数是评判规划航路的重要性能指标。综合雷达威胁和燃料代价,得到如下代价函数:

$$F = k T_{total} + (1 - k) \omega_f \quad (7)$$

其中, T_{total} 为所受雷达威胁; ω_f 为耗油代价; $k \in [0, 1]$ 为动态因子,可根据实际任务选择加权因子。当 k 接近于 0 时,以牺牲雷达威胁方式规划最优路径;当 k 接近于 1 时,则以牺牲路径方式避免雷达威胁。航路规划指在 F 达到最小值时规划的路径。

1.4 规划空间的栅格化表示

图 1 为规划空间栅格化示意图。图中 $\tau_1 \sim \tau_4$ 表明威胁源,其威胁区域如图中阴影所示; S 为无人机起飞点位置; E 为无人机目标点位置;定义规划空间的纵向为 X ,横向为 Y 。分别沿着 X 和 Y 方向将规划空间进行 m 等分和 n 等分,则规划空间可等效为由 $(m+1)(n+1)$ 个节点组成的栅格图。因此,无人机的航路规划指通过在栅格节点上移动方式从起飞点 S 移动到目标点 E 。设 $P(x_k, y_k)$ 表明由 X 轴的第 x_k 个等分线与 Y 轴的第 y_k 个等分线相交产生的节点位置坐标,若无人机从起飞点 S 经过 h 个节点到达目标点 E ,则航路如下:

$$P = \{S, P(x_1, y_1), P(x_2, y_2), \dots, P(x_h, y_h), E\} \quad (8)$$




图 1 规划空间栅格化示意图

2 基于蚁群算法的航路规划

2.1 蚁群算法

蚁群算法的数学模型可抽象为旅行商问题(TSP)。TSP 简述为寻找一条从 n_c 个城市中的某一个城市出发,访问且仅访问一次其他城市后回到出发城市的最短路线。

设 $b_i(t)$ 表明在 t 时刻处于第 i 个城市的蚂蚁数, $\tau_{ij}(t)$ 为在 t 时刻连接城市 i 到城市 j 间路径上的信息素值, n_c 为城市数, N_a 为蚁群数,则满足 $N_a = \sum_{i=1}^{n_c} b_i(t)$ 。 $\Gamma = \{\tau_{ij}(t) \mid i, j \in n_c\}$, 表明 t 时刻两两连接的城市间路径上信息素的集合,在 $t=0$ 时,集合 Γ 中所有元素相等且满足 $\tau_{ij}(0) = \text{const}$ 。首先, N_a 只蚂蚁任意选择不同城市为出发点,且每个城市上蚂蚁数是随机的。第 k ($k \in N_a$) 只蚂蚁在移动过程中按照两两城市间路径上信息素值判断下一个要去的城市。在搜索过程中,蚂蚁 k 依据两两城市间路径上信息素含量和路径的启发信息计算从城市 i 转移到城市 j 的转移概率 $P_{i,j}^k(t)$, 满足如下公式:

$$P_{i,j}^k(t) = \begin{cases} \frac{\tau_{ij}^\alpha(t) \eta_{ij}^\beta(t)}{\sum_{s \in A_{\text{Allow},k}} \tau_{is}^\alpha(t) \eta_{is}^\beta(t)} & j \in A_{\text{Allow},k} \\ 0 & \text{其他} \end{cases} \quad (9)$$

其中, $A_{\text{Allow},k}$ 表明蚂蚁 k 下一步可以选择访问的城市集合,在初始时刻, $A_{\text{Allow},k}$ 初值为除蚂蚁出发城市外的所有城市,随着蚂蚁的不断搜索, $A_{\text{Allow},k}$ 中元素逐渐减少; α 表明信息素启发作用的强度, α 越大表明蚂蚁 k 在选择路径时将更多选择前面蚂蚁留下的信息素强的路径; β 表明期望启发作用的强度, β 越大表明蚂蚁在移动过程中更注重选择期望值高的路径; $\eta_{ij}(t)$ 为启发函数,表明在 t 时刻的蚂蚁从城市 i 移动到城市 j 的期望值^[17], 满足:

$$\eta_{ij}(t) = 1/d_{ij} \quad (10)$$

其中, d_{ij} 为城市 i 与城市 j 间路径长度, d_{ij} 越小, $\eta_{ij}(t)$ 越大,搜索出的路径长度则越短。

2.2 基于蚁群算法的无人机航路规划

如果将无人机的起飞点视作蚁穴,目标点视作食物源,则无人机航路规划过程可转化为蚁群寻找最优或次优路径的过程。与 TSP 类比,无人机航路规划就是在特定的飞行环境和约束条件下寻找一条从起飞点到目标点的使航路代价值最低的路径。在

栅格化任务空间中,确定无人机的起飞点和目标点及威胁信息,给出了无人机的约束条件。

假设蚁群数量为 N_a , 蚂蚁初始信息素值和信息素增量均设为 0, 即 $\tau_{ij}(0)=0, \Delta\tau_{ij}(0)=0$, 路径存储表清零。先将所有蚂蚁放在在无人机起飞点处, 蚂蚁根据信息素浓度和启发信息值选择下一个节点或目标点, 第 $k(k=1, 2, \dots, N_a)$ 只蚂蚁按照式(9)所示的状态转移概率从节点 i 转移到相邻节点 j 。此时, 式(9)中 $A_{\text{Allow}, k}$ 为与节点 i 相邻且满足约束条件的候选节点集合, $\tau_{ij}(t)$ 为节点 i 与节点 j 间路径上的信息素浓度, 蚂蚁从节点 i 转移到节点 j 的期望函数 $\eta_{ij}(t)$ 满足:

$$\eta_{ij}(t) = 1/J_{ij} \quad (11)$$

其中, J_{ij} 为节点 i 与节点 j 间航路段的综合航路代价值。

蚂蚁在释放信息素的同时, 各条航路段上信息素也在不断挥发。当蚂蚁寻找到一条连接起飞点和目标点的路径后, 需按照以下公式对栅格环境中每一条航路进行信息素更新:

$$\tau_{ij}(t+1) = (1-\rho)\tau_{ij}(t) + \Delta\tau_{ij}(t) \quad (12)$$

$$\Delta\tau_{ij}(t) = \sum_{k=1}^{N_a} \Delta\tau_{ij}^k(t) \quad (13)$$

其中, ρ 为信息素挥发因子, 则 $1-\rho$ 为信息素残留因子, 为避免信息素无限增加, 设置 $\rho \in (0, 1)$; 第 $t+1$ 次开始搜索前的信息素包括 2 部分, 一部分为 $(1-\rho)\tau_{ij}(t)$, 表明第 t 次循环中从节点 i 转移到节点 j 的路径上原有信息素的剩余量, 另一部分为 $\Delta\tau_{ij}(t)$, 表明第 t 次循环中该路径上新增信息素的值。依据 Ant-Density (蚁群密度) 模型^[18], 其中 $\Delta\tau_{ij}^k(t)$ 满足下式:

$$\Delta\tau_{ij}^k(t) = \begin{cases} Q/J_k & \text{蚂蚁 } k \text{ 从 } i \text{ 转移到 } j \\ 0 & \text{其他} \end{cases} \quad (14)$$

其中, J_k 表明蚂蚁 k 在本次搜索中获得路径的航路代价值。

3 基于改进混沌蚁群优化算法的航路规划

蚁群算法在进行无人机航路规划时存在操作时间长, 收敛效率低, 易陷入局部最优等缺陷。混沌理论利用混沌运动特有的内在遍历性、规律性和随机性可在一定范围内不重复地遍寻所有状态, 跳出局部最优解, 具有良好的计算精度和全局寻优能力。因此, 将混沌理论加入基本蚁群算法可有效改善算法弊端, 从而规划出全局最优航迹。

3.1 混沌理论

通过确定性方程获得的运动状态称为混沌, 混沌运动存在于非线性系统, 是普遍存在而又极其复杂的现象, Logistic 映射是典型的一维混沌映射, 其解析式为:

$$x(n+1) = \mu x(n)(1-x(n)) \quad (15)$$

其中, $n=0, 1, 2, \dots$; μ 为控制参数, $\mu \in [0, 4]$; $\{x(n) | n=0, 1, \dots\}$ 为当初值 $x(0) \in [0, 1]$ 时迭代产生的序列, $x(n) \in [0, 1]$ 。Logistic 映射分叉图如图 2 所示。图 2 给出了不同初值和控制参数条件的 Logistic 映射序列图, 表明在不同初值 $x(0)$ 和参数 μ 条件下, 变量 $x(n)$ 随着迭代次数 n 的变化而产生的数值变化情况, 并且给出了序列 $\{x(n)\}$ 状态由定态到周期逐次加倍、最后进入完全混沌状态的过程。




图 2 Logistic 映射分叉图

采用混沌优化算法进行搜索的过程包括: 首先, 利用映射方程迭代产生的混沌序列对整个解空间进行迭代搜索, 并把搜索到的解作为当前最优解; 其次, 在当前最优解的邻域内引入混沌扰动进行一定范围的细搜索, 除非达到算法终止要求, 输出最优解的值, 否则继续搜索。

3.2 混沌优化算法的改进

通过统计 Logistic 映射在初始值 $x(0)=0.612$ 的条件下分别迭代 100、1 000 和 10 000 次产生的混沌序列在各区间内占的比例, 绘制 Logistic 映射分布统计如表 1 所示。

表 1 Logistic 映射分布统计 %

分布区间	迭代 100 次	迭代 1 000 次	迭代 10 000 次
[0, 0.3]	37	37.4	36.78
(0.3, 0.7]	25	26.2	26.20
(0.7, 1]	38	36.4	37.02

由表1可知, Logistic映射无论迭代多少次,落在区间 $(0.3, 0.7]$ 的概率基本不变,且明显小于落在两端区间的概率,即整个 Logistic映射呈现非均匀分布,因此,仅提高迭代次数无法显著提高混沌运动的遍历性。当初始值发生改变时,通过 Logistic映射得到的概率密度分布不变,因此多轨道并行搜索也无法显著提高混沌运动的遍历性。针对上述特点,本文提出以下改进措施:

1) 根据 Logistic映射分布特点,通过变尺度调整调节系数 α_i ,先进行大范围的粗略搜索,随着迭代次数增加,逐步减小 α_i ,缩小搜索范围,加快收敛速度。

2) 针对 Logistic映射在单侧邻域内搜索的特点,引入 Ulam_von Neumann映射,使算法在解 x^* 的双侧邻域内进行搜索。Ulam_von Neumann映射的解析式如下:

$$y_{n+1} = 1 - \nu y_n^2 \quad (16)$$

其中, ν 为控制参数, $\nu \in [0, 2]$; y_n 为当初始 $y_0 \in [-1, 1]$ 时迭代产生的变量, $y_n \in [-1, 1]$, $n=0, 1, 2, \dots$ 。图3为 Ulam_von Neumann映射分叉图,描述了序列 y_n 与 ν 间的变化关系。由图3可知,当 $\nu=2$ 时,序列 y_n 在 $[-1, 1]$ 区间上处于完全混沌。本文采用 $\nu=2$ 的 Ulam_von Neumann映射作为另一混沌产生器。




图3 Ulam_von Neumann映射分叉图

3.3 基于改进混沌蚁群算法的航路规划设计

本文的无人机航路规划优化算法设计思路为:将混沌优化算法应用到蚁群算法的初始环节中以此设置初始信息素值,采取变尺度混沌局部再搜索机制和引入混沌扰动信息素更新策略,有效克服局部最优的缺点,提高搜索效率。

基于改进混沌蚁群算法的航路规划设计步骤如下:

1) 航路规划任务环境建模。任务环境建模环

节已在第2章详细阐述。以二维栅格任务空间为例,选取任意段 $i \rightarrow j$ 。其中, i 为已寻优过的规划点,也称当前规划点; j 为待寻优的规划点,也称候选规划点。每只蚂蚁的每个当前规划点 i 除边界外均有8个候选规划点 j ,且无人机规划出的航路由该类规划点组成。

2) 混沌优化算法初始化,得到初始混沌路径。初始化蚁群规模数目为 N_a ,蚂蚁活动范围为 $[a, b]$,引入随机函数以产生混沌映射的初始值 $x(0)$ 。通过 Logistic映射迭代 $N_a - 1$ 次产生混沌序列 $\{X_c\}$,将混沌序列 $\{X_c\}$ 中变量分别进行载波映射得到新的混沌序列 $\{X_d\}$,上述过程如下:

$$\{X_c\} = \{x(0), x(1), \dots, x(N_a - 1)\} \quad (17)$$

$$\{X_d\} = a + (b - a)\{X_c\} \quad (18)$$

$$\{X_d\} = \{x'(0), x'(1), \dots, x'(N_a - 1)\} \quad (19)$$

式(19)中, a 和 b 为蚁群搜索范围 $[a, b]$ 的边界。最后,将序列 $\{X_d\}$ 中 N_a 个新混沌变量利用全排列构造原理构造出 $N_a!$ 条不同的初始混沌路径。

3) 设置航路代价函数。

4) 获取初始信息素值。将通过步骤2)产生的 $N_a!$ 条初始混沌路径代入步骤3)中航路代价函数,从中选择前 N_a 个最小值并取倒数,以此作为改进蚁群算法的信息素初值。

5) 初始化迭代次数 $u = 0$,最大迭代次数为 N_{cmax} 。

6) 将 N_a 只蚂蚁均置于起始点,每只蚂蚁根据式(11)所示的启发函数 $\eta_{ij}(t)$ 和信息素浓度函数 $\tau_{ij}(t)$,按照式(10)所示状态转移概率 $P_{i,j}^k(t)$ 选择下一节点,直至所有蚂蚁均搜索到目标点,则输出 N_a 个航路。计算这 N_a 个航路对应的航路代价值,从中择优得出当前迭代次数 u 下的最优解。假设当前迭代次数 u 下的最优解为第 $t(t \in [1, N_a])$ 只蚂蚁寻找的路径,记作 $P_{\text{best}}(u, t)$,初始化为 $P_{\text{best}}(u, t)$ 。当迭代次数 $u \geq 1$ 时,满足:

$$P_{\text{best}}(u, t) = \min\{P_{\text{best}}(u, t), P_{\text{best}}(u - 1, t)\} \quad (20)$$

其中, $P_{\text{best}}(u - 1, t)$ 为上一次迭代次数下最优解。

7) 引入变尺度混沌局部再搜索机制,进行局部再搜索。以上一步骤产生的 $P_{\text{best}}(u, t)$ 为基础,通过以下2个公式产生 ϵ 个在对应于最优解 $P_{\text{best}}(u, t)$ 的搜索点附近具有混沌特性的搜索点集合 W ,计算 ϵ 个搜索点的航路代价值,并将它们与 $P_{\text{best}}(u, t)$ 进行比较,取两者的最小值替换 $P_{\text{best}}(u, t)$ 。这些

搜索点的计算公式如下:

$$W = \{w(p) | p = 1, 2, \dots, \epsilon\} \quad (21)$$

$$w(p) = P_{\text{best}}(u, t) + \alpha_r y_p a_{\text{random}}^3 \quad (22)$$

其中, $P_{\text{best}}(u, t)$ 为当前解; a_{random} 为伪随机数; y_p 为混沌变量, 是通过 Ulam_von Neumann 映射产生的混沌变量, 满足:

$$y_p = \begin{cases} 2a_{\text{random}} - 1 & p = 1 \\ 1 - 2y_{p-1}^2 & p > 1 \end{cases} \quad (23)$$

α_r 为调节系数, 满足:

$$\alpha_r = \alpha_r \gamma^u \quad (24)$$

其中, γ 为衰减系数; u 为当前的迭代次数。引入可变 α_r , 可不断改变搜索空间大小; 同时引入 a_{random}^3 可进一步缩小搜索空间, 提高收敛速度。

8) 引入混沌扰动的信息素更新策略, 对上述寻优得到的航路按下式进行全局信息素更新:

$$\tau_{ij}(t+1) = (1 - \rho(t)) \tau_{ij}(t) + \rho(t) (\Delta \tau_{ij}(t) + \Delta \tau_{ij}^b(t)) + y(n+1) \quad (25)$$

式(25)增加了由 Ulam_von Neumann 映射产生的混沌扰动因子 $y(n+1)$ 及用下式改进后的 $\rho(t)$ 替换原来的 ρ :

$$\rho(t+1) = \begin{cases} \rho_{\min} & \rho(t) \leq \rho_{\min} \\ \lambda \rho(t) & \rho_{\min} < \rho(t) < \rho_{\max} \\ \rho_{\max} & \rho(t) \geq \rho_{\max} \end{cases} \quad (26)$$

其中, ρ_{\min} 和 ρ_{\max} 分别为信息素挥发因子的最小值和最大值, 本文取 $\rho \in (0.15, 0.95)$; λ 为挥发因子调整系数, 且 $\lambda \in (0, 1)$ 。为了准确模拟真实环境下蚁群信息素的挥发情况, 引入 $(0, 1)$ 范围内随机数 ρ_{rand} , 并利用该随机数对 λ 进行调整, 满足下式:

$$\lambda = (\rho_{\text{rand}} - \rho_{\min}) / (\rho_{\max} - \rho_{\min}) \quad (27)$$

式(25)中 $y(n+1)$ 满足:

$$y(n+1) = 1 - 2y^2(n) \quad (28)$$

9) 保存当前迭代次数 u 下最优航路和最优解,

迭代次数 $u = u + 1$, 将蚂蚁重新置于起始点, 开始新一轮搜索。当 $u > N_{\text{cmax}}$ 时, 寻优结束, 输出最优航路和对应的代价值。

4 仿真结果与分析

仿真验证环境分为简单和复杂 2 种环境。简单环境中仅存在一种静态威胁源, 等效为半径为 2 km 的圆; 复杂环境中存在 2 种不同类型的静态威胁源, 等效为半径分别为 2 和 4 km 的圆, 同时还存在动态威胁源, 等效为半径为 3 km 的圆, 通过添加动态威胁源, 可以验证比较蚁群算法和改进混沌蚁群算法在规划航路时处理动态威胁的性能。

初始化算法参数: 蚁群数目 $N_a = 30$, 最大迭代次数 $N_{\text{cmax}} = 200$, 信息素重要程度因子 $\alpha = 1$, 能见度重要程度因子 $\beta = 0.8$, 信息素挥发因子 $\rho = 0.5$, 信息素总量 $Q = 100$, 衰减系数 $\gamma = 0.96$, 初始调节系数 $\alpha_r = 0.1$, 迭代次数 u 初始值设为 0。

分别采用 ACA 和改进 CACA 在简单和复杂 2 种飞行环境下进行航路规划仿真试验。简单和复杂 2 种飞行环境仿真试验结果如图 4 和图 5 所示。图中, UAV 为无人机的起飞点; 图 4(a) 和图 5(a) 中横轴和纵轴分别为飞行的横向和纵向范围。

由图 4(b) 可知, 当迭代次数达 46 次时, 采用 ACA 规划航路的航路代价值趋于一个稳定值, 而对于采用改进 CACA 规划的航路, 迭代次数仅 26 次时, 航迹代价值就达到了全局最优。在航迹代价值趋于稳定时的迭代次数上, 采用改进 CACA 规划出的航路所需的迭代次数小于采用 ACA 规划出的航路所需的迭代次数, 即采用改进 CACA 规划航路比采用 ACA 规划航路收敛效率更高, 收敛速度更快。

由图 5(b) 可知, 当迭代次数达到 18 次时的迭代搜索中, ACA 仍判断当前解为最优解; 而改进


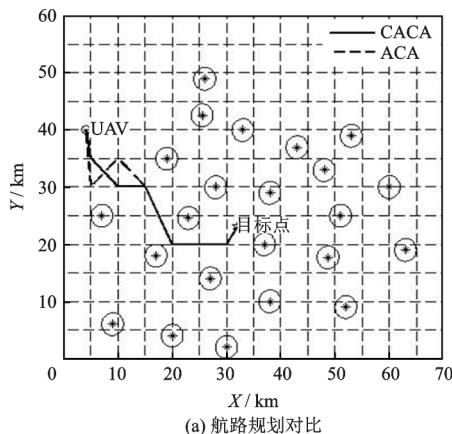


图 4 简单飞行环境仿真试验结果

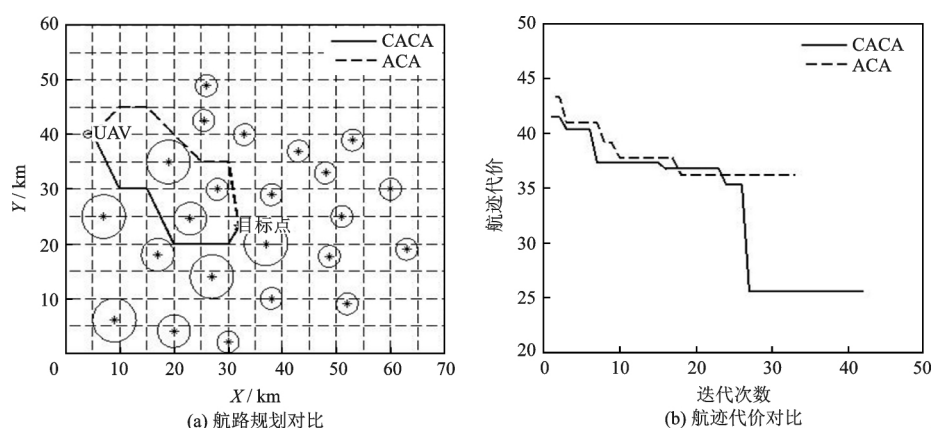


图5 复杂飞行环境仿真试验结果

CACA 由于加入混沌局部再搜索机制,能跳出当前最优解,寻找航迹代价值更低、性能更优的航路;当迭代次数达到 25 次时,航路代价值迅速减小,且达到了全局最优。因此,与采用 ACA 进行航路规划相比,采用改进 CACA 进行航路规划能跳出局部最优,具有更强的全局搜索能力。在迭代次数达到 18 次之前,在相同的迭代次数下,采用改进 CACA 规划出的航路代价值低于采用 ACA 的,同样可得在进行航路规划时改进 CACA 比 ACA 能跳出局部极值,搜索精度高。

5 结束语

针对 ACA 在进行无人机航路规划时存在操作时间长、收敛效率低、易陷入局部最优等缺陷,利用混沌的遍历性特点,本文提出一种改进的混沌蚁群算法。该算法将混沌优化算法应用于 ACA 的初始环节以此设置初始信息素值,采取变尺度混沌局部再搜索机制和引入混沌扰动信息素更新策略。同时在复杂飞行环境下进行了仿真试验,结果表明:相比于基于 ACA 的航路规划,采用改进 CACA 规划航路既有效避免了局部最优,又能提高收敛效率,并验证了改进 CACA 在解决无人机二维航路规划问题的有效性。

参考文献(References):

- [1] 邢立宁, 陈英武. 任务规划系统研究综述[J]. 火力与指挥控制, 2006, 31(4): 1-4.
XING Lining, CHEN Yingwu. Overviews on mission planning system research[J]. Fire Control and Command Control, 2006, 31(4): 1-4. (in Chinese)
- [2] 丁明跃, 郑昌文, 周成平, 等. 无人飞行器航迹规划[M]. 北京: 电子工业出版社, 2009.
- [3] DALAMAGKIDIS K, VALAVANIS K P, PIEGL L

- A. Unmanned aircraft systems regulation[M]//On Integrating Unmanned Aircraft Systems into the National Airspace System. 2nd ed. Netherlands: Springer, 2012: 57-90.
- [4] DENTON R V, JONES J E, FROEBERG P L. Demonstration of an innovative technique for terrain following/terrain avoidance-the dynapath algorithm [C]//Proceedings of the IEEE 1985 National Aerospace and Electronics Conference. [S.l.]: IEEE, 1985: 228-260.
- [5] KARAMAN S, FRAZZOLI E. Linear temporal logic vehicle routing with applications to multi-UAV mission planning[J]. International Journal of Robust and Nonlinear Control, 2011, 21(12): 1372-1395.
- [6] 屠文森, 汪佳佳. Voronoi 图栅格生成算法 GPU 并行实现[J]. 现代电子技术, 2015, 38(4): 66-68.
TU Wensen, WANG Jiajia. Raster-based method for Voronoi diagram using GPU parallel technology[J]. Modern Electronics Technique, 2015, 38(4): 66-68. (in Chinese)
- [7] ROBERGE V, TARBOUCHI M, LABONTE G. Comparison of parallel genetic algorithm and particle swarm optimization for real-time UAV path planning [J]. IEEE Transactions on Industrial Informatics, 2013, 9(1): 132-141.
- [8] KOENIG S, LIKHACHEV M. Real time adaptive A*[C]//Proceedings of the fifth International Joint Conference on Autonomous Agents. New York: ACM, 2006: 281-288.
- [9] XIN Y, DING M Y, ZHOU C P. Fast marine route planning for UAV using improved sparse A* algorithm[C]//Proceedings of 2010 Fourth International Conference on Genetic and Evolutionary Computing. Shenzhen: IEEE, 2010: 190-193.
- [10] SZCZERBA R J, GALKOWSKI P, GLICKTEIN I S, et al. Robust algorithm for real-time route planning

- [J]. IEEE Transactions on Aerospace and Electronic Systems, 2000,36(3):869-878.
- [11] TISDALE J, KIM Z, HEDRICK J K. Autonomous UAV path planning and estimation[J]. IEEE Robotics & Automation Magazine, 2009,16(2):35-42.
- [12] PARUNAK H V, PURCELL M, O'CONNELL R. Digital pheromones for autonomous coordination of swarming UAV's[C]//Proceedings of 1st UAV Conference. [S.l.]:AIAA, 2002.
- [13] 孔天恒, 方舟, 李平. 基于雷达-扫描器/惯性导航系统的微小型无人机室内组合导航[J]. 控制理论与应用, 2014,31(5):607-613.
KONG Tianheng, FANG Zhou, LI Ping. Indoor integrated navigation of micro aerial vehicle based on radar-scanner and inertial navigation system[J]. Control Theory and Application, 2014,31(5):607-613. (in Chinese)
- [14] 陈晓飞, 董彦非. 精密进场雷达引导无人机自主着陆综述[J]. 航空科学技术, 2014,25(1):69-72.
CHEN Xiaofei, DONG Yanfei. Review of precision approach radar guide unmanned aerial vehicle(UAV) automatic landing[J]. Aeronautical Science & Technology, 2014,25(1):69-72. (in Chinese)
- [15] 刘振峰, 谢洪森, 危水根. 基于蚁群遗传算法的三维飞行器航路规划[J]. 计算机仿真, 2013,30(9):121-125.
LIU Zhenfeng, XIE Hongsen, WEI Shuigen. Three-dimension route planning of aircraft based on ant genetic algorithm[J]. Computer Simulation, 2013,30(9):121-125. (in Chinese)
- [16] 饶跃东. 基于改进蚁群算法的无人飞行器航迹规划应用研究[D]. 武汉:武汉理工大学, 2010:1-10.
- [17] 王丽婧. 免疫遗传算法-有限元的结构优化方法研究[D]. 南京:南京航空航天大学, 2007.
- [18] 段海滨. 蚁群算法原理与应用[M]. 北京:科学出版社, 2005.

作者简介:

刘 蓉,女(1981—),副研究员,研究方向为无人机飞行控制和无人机航路规划。

杨 帆,女(1991—),助教,研究方向为无人机航路规划。

张 衡,男(1993—),硕士研究生,研究方向为无人机航路规划。

(本文编辑:李素华)